



Dolne granice

Ponieważ od drzew decyzyjnych wymagamy by były skończone, jedno drzewo nie może reprezentować działania algorytmu dla dowolnych danych. Z reguły przyjmujemy, że algorytm reprezentowany jest przez nieskończoną rodzinę drzew decyzyjnych $\{D_i\}_{i=1}^\infty$, gdzie drzewo D_n odpowiada działaniu algorvtmu na danvch o rozmiarze n .



Rysunek 1: Drzewo D_3 dla algorytmu sortowania przez selekcję.



Rysunek 2: Optymalne drzewo decyzyjne dla algorytmów sortujących ciągi 3-elementowe.

Fakt 1 Niech \mathcal{A} będzie algorytmem sortującym, a $\{D_i\}_{i=1}^\infty$ – odpowiadającą mu rodziną drzew decyzyjnych. Wówczas drzewo D_n posiada co najmniej $n!$ liści, dla każdego n .

UZASADNIENIE: Każda permutacja ciągu wejściowego może być wynikiem, a każdy liść drzewa D_n odpowiada jednemu wynikowi. \square

Twierdzenie 1 Niech \mathcal{A} będzie algorytmem sortującym, a $\{D_i\}_{i=1}^\infty$ – odpowiadającą mu rodziną drzew decyzyjnych. Wówczas drzewo D_n ma wysokość co najmniej $\Omega(n \log n)$.

UZASADNIENIE: Drzewo binarne o $n!$ liściach (a takim jest D_n) musi mieć wysokość co najmniej $\log(n!)$. Ze wzoru Stirlinga, $n!$ możemy z dołu oszacować przez $(n/e)^n$, co daje nam:

$$\log n! \geq n (\log n - \log e) \geq n \log n - 1.44n$$

Wniosek 1 Każdy algorytm sortujący za pomocą porównań ciąg n - elementowy wykonuje co najmniej $cn \log n$ porównań dla pewnej stałej $c > 0$.

2.1 Ograniczenie na średnią złożoność

Działanie algorytmu sortowania, który dane wykorzystuje wyłącznie w porównaniach, zależy jedynie od względnego porządku pomiędzy elementami. W szczególności nie zależy ono od bezwzględnych wartości elementów. Dlatego badając złożoność takich algorytmów możemy ograniczać się do analizy zachowania algorytmu na permutacjach zbioru $\{1, 2, \dots, n\}$, a średnia złożoność algorytmu na danych rozmiaru n może być policzona jako suma:

$$\sum_{\sigma \in S_n} P[\sigma] c(\sigma),$$

gdzie S_n jest zbiorem permutacji zbioru $\{1, 2, \dots, n\}$, $P[\sigma]$ jest prawdopodobieństwem wystąpienia permutacji σ jako danych wejściowych, a $c(\sigma)$ jest równa liczbie porównań wykonywanych na tych danych. W języku drzew decyzyjnych można ją wyrazić jako średnią wysokość drzewa, tj.

$$\sum_{v - \text{liść } T} p_v d_v,$$

gdzie p_v oznacza prawdopodobieństwo dojścia do liścia v , a d_v - jego głębokość.

Twierdzenie 2 Jeżeli każda permutacja ciągu n -elementowego jest jednakowo prawdopodobna jako dana wejściowa, to wówczas każde drzewo decyzyjne sortujące ciągi n -elementowe ma średnią głębokość co najmniej $\log n!$.

UZASADNIENIE: Na głębokości nie większej niż $\log(n/e)^n - 1$ znajduje się mniej niż $n!/2$ liści. Tak więc co najmniej $n!/2$ liści osiągalnych z prawdopodobieństwem $1/n!$ leży na głębokości większej, co implikuje, że średnia wysokość drzewa decyzyjnego jest większa niż $(1/n!)(n!/2) \log((n/e)^n)$. \square

Gra z adwersarzem

Twierdzenie 3 Każdy algorytm rozwiązujący powyższy problem (i używający elementów zbioru S jedynie w porównaniach) wykonuje co najmniej $\lceil \frac{3}{2}n - 2 \rceil$ porównań. (ALG MIN MAX1)

DOWÓD: Rozważmy następującą grę między algorytmem a złośliwym adwersarzem:

- Sytuacja początkowa: adwersarz twierdzi, że zna trudny dla algorytmu zbiór S , tj. taki, dla którego wskazanie przez algorytm minimum i maksimum będzie wymagało wykonania co najmniej $\lceil \frac{3}{2}n - 2 \rceil$ porównań. Algorytm nie zna S ; wie tylko, że liczy on n elementów.

- Cel gry

- algorytmu: wskazanie indeksów elementów minimalnego i maksymalnego w zbiorze S przy użyciu mniej niż $\lceil \frac{3}{2}n - 2 \rceil$ porównań;
- adwersarza: zmuszenie algorytmu do zadania co najmniej $\lceil \frac{3}{2}n - 2 \rceil$ porównań.

- Ruchy

- algorytmu: pytanie o porównanie dwóch elementów ze zbioru S ;
- adwersarza: odpowiedź na to pytanie.

- Koniec gry następuje, gdy algorytm wskaże minimum i maksimum w S . Wówczas adwersarz ujawnia zbiór S .

Tezę twierdzenia udowodnimy, jeśli pokażemy, że adwersarz zawsze, niezależnie od algorytmu, posiada strategię wygrywającą.

Zadania Egzaminacyjne

Treść

Dolną granicę $\lceil \frac{3}{2}n - 2 \rceil$ na liczbę porównań niezbędnych do wyznaczenia max i min w n elementach zbioru S można osiągnąć, jeśli S jest zbiorem n elementów, a adwersarzem.

Opisz skuteczną strategię w takiej grze.

Jeśli jest to strategia opisana na wykładzie, możesz na tym poprzestać.

Jeśli jest to inna strategia, wykaż, że jest skuteczna.

Treść

Na wykładzie pokazaliśmy, że $\Omega(n \log n)$ jest dolną granicą na złożoność problemu Element Uniqueness w modelu liniowych drzew decyzyjnych.

Podaj definicję tego problemu.

Co można powiedzieć o dolnej granicy na złożoność tego problemu w modelu (zwykłych) drzew decyzyjnych?

▼ Rozwiązanie

PROBLEM: (RÓŻNOŚĆ ELEMENTÓW)

Dane: Liczby rzeczywiste x_1, x_2, \dots, x_n .

Zadanie: Sprawdzić, czy $\forall 1 \leq i < j \leq n, x_i \neq x_j$.

Dolna granica na złożoność tego problemu w modelu zwykłych drzew decyzyjnych to $\log_2(2) = 1$, ponieważ mamy jedynie dwa liście z odpowiedziami TAK albo NIE. Ale ta odpowiedź jest bezwartościowa, ponieważ nie jesteśmy w stanie jednym pytaniem sprawdzić, czy zbiór nie zawiera czy zawiera duplikaty.

Strategia dla adwersarza:

- W trakcie gry adwersarz dzieli S na 4 rozłączne zbiory:

$A = \{i \mid a_i \text{ jeszcze nie był porównywany}\},$
 $B = \{i \mid a_i \text{ wygrał już jakieś porównanie i nie przegrał żadnego}\},$
 $C = \{i \mid a_i \text{ przegrał już jakieś porównanie i nie wygrał żadnego}\},$
 $D = \{i \mid a_i \text{ wygrał już jakieś porównanie i jakieś już przegrał}\}.$

Początkowo oczywiście $|A| = n$ oraz $|B| = |C| = |D| = 0$.

- Adwersarz rozpoczyna grę z dowolnymi kandydatami na wartości elementów a_i . W trakcie gry będzie, w razie konieczności, modyfikował te wartości, tak by spełniony był warunek

$$(*) \quad \forall a \in A \forall b \in B \forall c \in C \forall d \in D \quad b > d > c \text{ oraz } b > a > c.$$

Zauważ, że wystarczy w tym celu zwiększać wartości elementów o indeksach z B i zmniejszać wartości elementów o indeksach z C . Takie zmiany są bezpieczne dla adwersarza, ponieważ pozostawiają prawdziwymi jego odpowiedzi na dotychczasowe pytania.

Fakt 4 Powyższa strategia adwesarza jest zawsze wygrywająca.

DOWÓD FAKTU: W trakcie gry wszystkie elementy przechodzą ze zbioru A do B lub C , a dopiero stąd do zbioru D . Ponadto dla danych spełniających (*):

- jedno porównanie może usunąć co najwyżej dwa elementy ze zbioru A ,
- dodanie jednego elementu do zbioru D wymaga jednego porównania,
- porównania, w których bierze udział element z A , nie zwiększają mocy zbioru D .

Dopóki A jest niepusty lub któryś ze zbiorów B lub C zawiera więcej niż jeden element, algorytm nie może udzielić poprawnej odpowiedzi. Na opróżnienie zbioru A algorytm potrzebuje co najmniej $\lceil n/2 \rceil$ porównań. Następnych $n - 2$ porównań potrzebnych jest na przesłanie wszystkich, poza dwoma, elementów do zbioru D . \square (faktu i twierdzenia)

1. (1pkt) Pokaż, że problem znajdowania otoczki wypukłej nie może być rozwiązany w modelu drzew decyzyjnych.
2. (2pkt) Rozważmy następujący problem:

Zadania z Ćwiczeń

PROBLEM *3SUM*:

Dane: Liczby rzeczywiste x_1, \dots, x_n .

Wynik: 'TAK' - jeśli $\exists_{1 \leq i < j < k \leq n} x_i + x_j + x_k = 0$,
 'NIE' - w przeciwnym przypadku.

Udowodnij, że $\Omega(n \log n)$ jest dolną granicą na rozwiązanie tego problemu w modelu liniowych drzew decyzyjnych.

3. (1,5pkt) Ułóż algorytm rozwiązujący problem *3SUM* w czasie $O(n^2)$.
4. (Z 2pkt) Rozwiąż poprzednie zadanie dla takiej "wersji" problemu *3SUM*, w której operacja dodawania jest zastąpiona operacją *XOR*, tj. chcemy sprawdzić, czy w danym ciągu istnieją elementy a, b, c , takie że $a \oplus b \oplus c = 0$.
5. (2pkt) Rozważmy problem, polegający na sprawdzeniu, czy w zbiorze n punktów leżących na płaszczyźnie znajdują się co najmniej 3 punkty współliniowe. Udowodnij, że problem ten nie jest prostszy niż problem *3SUM*, a dokładniej, że istnienie algorytmu rozwiązującego ten problem w czasie $o(n^{2-\epsilon})$ implikuje istnienie algorytmu o złożoności $o(n^{2-\epsilon})$ dla problemu *3SUM*.
6. (1,5pkt) Udowodnij, że $2n - 1$ porównań trzeba wykonać, aby scalić dwa ciągi n elementowe w modelu drzew decyzyjnych. Zastosuj grę z adversarzem, w której adversarz na początku ogranicza przestrzeń danych tak, by zawierała $2n$ zestawów danych takich i by każde porównanie wykonane przez algorytm eliminowało co najwyżej jeden zestaw.
7. (Z 2pkt) Mamy dany ustalony zbiór permutacji na n elementach $F \subseteq S_n$. Chcemy posortować liczby x_1, x_2, \dots, x_n (używając tylko porównań) wiedząc, że ich permutacja sortująca należy do F . Pokaż, że istnieje dla tego problemu drzewo decyzyjne o głębokości $O(n + \log |F|)$.
8. (2pkt) W problemie *3D-Matching* dane są n elementowe zbiory A, B, C oraz zbiór uporządkowanych trójek $X \subseteq A \times B \times C$ a zadaniem jest sprawdzenie, czy istnieje n elementowy podzbiór $S \subseteq X$, taki że każdy element z $A \cup B \cup C$ należy do dokładnie jednej trójki z S .

Pokaż redukcję wielomianową problemu *3SAT* do problemu *3D-Matching*.

9. (2pkt) Rozważmy problem wyznaczenia za pomocą porównań elementów największego i drugiego z kolei w zbiorze n -elementowym. Udowodnij, że $n + \lceil \log n \rceil - 2$ porównań potrzeba i wystarcza do wyznaczenia tych elementów.

1. (0pkt) Pokaż, że $\Omega(n \log n)$ pozostaje dolną granicą dla problemu sortowania, jeśli w modelu drzew decyzyjnych na zapytania o relację między elementami a i b możliwe są trzy odpowiedzi: " $a < b$ ", " $a = b$ " i " $a > b$ ".
2. (1pkt) Pokaż, że problem "Element uniqueness" rozбивa R^n na $\Omega(n!)$ spójnych składowych.
3. (2pkt) Rozważmy następujący problem weryfikacji rozmiaru wielozbioru (MSV). Dany jest wielozbiór złożony z n liczb rzeczywistych oraz liczba naturalna k . Należy sprawdzić, czy w tym wielozbiorze jest dokładnie k różnych elementów. Postaraj się wskazać jak najwięcej różnych spójnych składowych, na które problem ten rozбивa R^n .
4. (2pkt) *Algebraiczne Drzewo Obliczeń* jest uogólnieniem algebraicznego drzewa decyzyjnego. Posiada ono dwa rodzaje wierzchołków:

- wierzchołki obliczeniowe: z każdym takim wierzchołkiem u związana jest wartość f_u , która jest określona jako wynik jednej z poniższych operacji:

$$f_u \leftarrow f_w + f_v, \quad f_u \leftarrow f_w - f_v, \quad f_u \leftarrow f_w * f_v, \quad f_u \leftarrow f_w / f_v, \quad f_u \leftarrow \sqrt{f_v},$$

gdzie f_w i f_v są wartościami skojarzonymi z pewnymi przodkami wierzchołka u lub są elementami ciągu wejściowego lub stałymi z R .

- wierzchołki rozgałęziające: wierzchołek v wykonuje test $f_u < 0$ bądź $f_u \geq 0$ bądź $f_u = 0$, gdzie u jest przodkiem v .

Problem Set Equality (SE) zdefiniowany jest następująco: dane są zbiory $X = \{x_1, \dots, x_n\}$ oraz $Y = \{y_1, \dots, y_n\}$; pytamy, czy $X = Y$. Pokaż, że jeśli dane dla problemu SE są liczbami całkowitymi, to problem ten może być rozwiązany w modelu Algebraicznych Drzew Obliczeń w czasie liniowym.

5. (1pkt) Rozważmy decyzyjną wersję problemu otoczki wypukłej: mamy dane n punktów p_1, \dots, p_n na płaszczyźnie oraz liczbę naturalną k . Pytamy, czy otoczka wypukła tego zbioru składa się z k punktów. Wiedząc, że problem MSV zdefiniowany w poprzednim zadaniu wymaga $\Omega(n \log k)$ operacji w modelu algebraicznych drzew decyzyjnych, pokaż, że w tym modelu decyzyjna wersja problemu otoczki także wymaga tylu działań.
6. (2pkt) Problem "Przekrój zbiorów" zdefiniowany jest następująco:

PROBLEM:

Dane: Liczby rzeczywiste $x_1, \dots, x_n, y_1, \dots, y_n$.

Wynik: 'TAK' - jeśli $\{x_1, \dots, x_n\} \cap \{y_1, \dots, y_n\} = \emptyset$
 'NIE' - w przeciwnym przypadku.

Udowodnij, że $\Omega(n \log n)$ jest dolną granicą na rozwiązanie tego problemu w modelu liniowych drzew decyzyjnych.