


Sortowanie

OSTAĆ DANYCH: Ciąg $A[1..n]$ liczb rzeczywistych z przedziału $(0, 1)$ wygenerowany przez generat czb losowych o rozkładzie jednostajnym.

```
procedure Counting – Sort( $A[1..n], k, \text{var } B[1..n]$ )
  for  $i \leftarrow 1$  to  $k$  do  $c[i] \leftarrow 0$ 
  for  $j \leftarrow 1$  to  $n$  do  $c[A[j]] \leftarrow c[A[j]] + 1$ 
  for  $i \leftarrow 2$  to  $k$  do  $c[i] \leftarrow c[i] + c[i - 1]$ 
  for  $j \leftarrow n$  downto  $1$  do  $B[c[A[j]]] \leftarrow A[j]$ 
                            $c[A[j]] \leftarrow c[A[j]] - 1$ 
```

- 1) Zainicjuj nową tablicę c (o długości zakresu zmiennych) zerami
- 2) Zlicz ilości występowania elementów w tablicy A do c (na i–tym indeksie w tablicy c znajduje się ilość występowania i w tablicy A
- 3) Do każdego elementu w tablicy c dodajemy poprzedni
- 4) Iterując od końca tablicy A wstawiamy jej element do nowej tablicy na miejsce odpowiadające c[element] i zmniejszamy tą komórkę o jeden tzn: c[e] = c[e] – 1 (Iterowanie od końca gwarantuje nam stabilność sortowania)

Przykład:



- Charakterystyka:
- ✓ Algorytm działa w czasie $O(m+k)$
 - ✗ Dane są ograniczone
- Counting Sort jest stabilny.

Def: Metodę sortowania nazywamy stabilną Jeśli elementy o tej samej wartości w ciągu wyjściowym pozostają w takiej samej kolejności względem siebie w jakiej były w ciągu wejściowym


```
procedure bucket – sort( $A[1..n]$ )
  for  $i \leftarrow 0$  to  $n - 1$  do  $B[i] \leftarrow \emptyset$ 
  for  $i \leftarrow 1$  to  $n$  do dołącz  $A[i]$  do listy  $B[\lfloor nA[i] \rfloor]$ 
  for  $i \leftarrow 0$  to  $n - 1$  do posortuj procedurą select – sort listę  $B[i]$ 
  połącz listy  $B[0], B[1], \dots, B[n - 1]$ 
```

Sortowanie elementów 0-1 mp. [0.41, 0.91, 0.49, 0.49, 0.24]

- 1. Stwórz listę n kubelków (array of linked lists)
- 2. Przypisz każdy element do kubelka wg. $\lfloor n \cdot \text{arr}[i] \rfloor$
- 3. Posortuj kubelki za pomocą insertSort

- Charakterystyka:
- ✓ złożoność określana $O(n)$
 - ✗ dane z konkretnego przedziału
 - ✗ zależy od danych (pesymistycznie $O(n^2)$)

Bucket Sort jest stabilny jeśli korzysta ze stabilnego alg. sortowania.



KOSZT: Oczekiwany czas działania: $\Theta(n)$.

UZASADNIENIE: Niech Y będzie zmienną losową równą liczbie porównań wykonanych podczas sortowania kubelków. Mamy

$$Y = Y_1 + \dots + Y_n,$$

gdzie Y_i jest zmienną losową równą liczbie porównań wykonanych podczas sortowania i -tego kubelka. Z liniowości wartości oczekiwanej mamy

$$E[Y] = \sum_{i=1}^n E[Y_i].$$

Niech X_i będzie zmienną losową równą liczbie elementów w i -tym kubelku. Oczywiście X_i ma rozkład dwumianowy, w którym prawdopodobieństwo sukcesu wynosi $1/n$. Ponieważ do sortowania kubelków stosujemy *select-sort*, mamy $Y_i = X_i^2$. Stąd wystarczy teraz oszacować $E[X_i^2]$. □

```
POSTAĆ DANYCH:  $A_1, \dots, A_n$  - ciągi elementów z  $\Sigma = \{0, 1, \dots, k - 1\}$  o długości  $d$ .
procedure radix – sort( $A_1, \dots, A_n$ )
  for  $i \leftarrow d$  downto  $1$  do
    metodą stabilną posortuj ciągi wg  $i$ -tego elementu
```

KOSZT: Jeśli w procedurze *Radix-sort* zastosujemy *counting-sort*, to jej koszt wyniesie $O((n+k)d)$ Jest to koszt liniowy, gdy $k = O(n)$.

POSTAĆ DANYCH: A_1, \dots, A_n ciągi elementów z $\Sigma = \{0, 1, \dots, k - 1\}$

Niech l_i oznacza długość A_i , a $l_{max} = \max\{l_i : i = 1, \dots, n\}$.

4.1 Pierwszy sposób

IDEA: Uzupełnić ciągi specjalnym elementem (mniejszym od każdego elementu z Σ), tak by miały jednakową długość i zastosować algorytm z poprzedniego punktu.

KOSZT: $\Theta((n + k) \cdot l_{max})$.

UWAGA: Jest to metoda nieefektywna, gdy ciągów długich jest niewiele.

4.2 Drugi sposób

Chcemy opracować metodę sortującą w czasie liniowym względem rozmiaru danych, który jest rów $l_{total} = \sum_{i=1}^n l_i$.

IDEA:

for $i \leftarrow l_{max}$ downto 1 do
metodą stabilną posortuj ciągi o długości $\geq i$ wg i -tej składowej

ALGORYTM:

```
1. Utwórz listy niepustekubelki[l] ( $l = 1, \dots, l_{max}$ ) takie, że
   •  $x \in \text{niepustekubelki}[l]$  iff  $x$  jest  $l$ -tą składową jakiegoś ciągu  $A_i$ .
   •  $\text{niepustekubelki}[l]$  jest uporządkowana niemalejąco.

2. Utwórz listy ciagi[l] ( $l = 1, \dots, l_{max}$ ) takie, że ciagi[l] zawiera
   wszystkie ciągi  $A_i$  o długości  $l$ .

3. kolśłów  $\leftarrow \emptyset$ 
   for  $j \leftarrow 0$  to  $k - 1$  do  $q[j] \leftarrow \emptyset$ 
   for  $l \leftarrow l_{max}$  downto  $1$  do
     kolśłów  $\leftarrow \text{concat}(\text{ciagi}[l], \text{kolśłów})$ 
     while kolśłów  $\neq \emptyset$  do
        $Y \leftarrow$  pierwszy ciąg z kolśłów
       kolśłów  $\leftarrow \text{kolśłów} \setminus \{Y\}$ 
        $a \leftarrow l$ -ta składowa ciągu  $Y$ 
        $q[a] \leftarrow \text{concat}(q[a], \{Y\})$ 
     for each  $j \leftarrow \text{niepustekubelki}[l]$  do
       kolśłów  $\leftarrow \text{concat}(\text{kolśłów}, q[j])$ 
        $q[j] \leftarrow \emptyset$ 
```

Operacja *concat*(K_1, K_2) łączy kolejkę K_2 do końca kolejki K_1 .

Twierdzenie 1 Powyższy algorytm można zaimplementować tak, by działał w czasie $O(k + l_{total})$.

UZASADNIENIE:

- Jedynym niezupełnie trywialnym krokiem jest krok 1, w którym tworzone są listy *niepustekubelki*:
- tworzymy w czasie $O(l_{total})$ ciąg P zawierający wszystkie pary $\langle l, a \rangle$, takie, że a jest l -tą składową jakiegoś A_i ;
- sortujemy leksykograficznie w czasie $O(k + l_{total})$ ciąg P ;
- przeglądając P z lewa na prawo tworzymy $O(l_{total})$ listy *niepustekubelki*.
Krok 2 wymaga czasu $O(l_{total})$.

Aby oszacować czas wykonania kroku 3, oszacujemy czas wykonania dwóch jego pętli wewnętrznych:

- Wewnętrzna pętla while działa w czasie proporcjonalnym do sumarycznej (po wszystkich iteracjach pętli zewnętrznej) długości kolejek *kolśw*. Ponieważ w l -tej iteracji *kolśw* ma długość równą liczbie ciągów co najmniej l -elementowych, więc koszt while jest $O(l_{total})$.
- Wewnętrzna pętla for działa w czasie proporcjonalnym do sumarycznej (po wszystkich iteracjach pętli zewnętrznej) długości list *niepustekubelki*. Ponieważ w każdej iteracji *niepustekubelki* jest nie dłuższa od *kolśw*, czas pętli for jest również $O(l_{total})$.

4.3 Przykład zastosowania

PROBLEM:
Dane: T_1, T_2 - drzewa o ustalonych korzeniach,
Zadanie: sprawdzić, czy T_1 i T_2 są izomorficzne.

IDEA: Wędrując przez wszystkie poziomy (począwszy od najniższego) sprawdzamy, czy na każdym poziomie obydwa drzewa zawierają taką samą liczbę wierzchołków tego samego typu (wierzchołki będą tego samego typu, jeśli poddrzewa w nich zakorzenione będą izomorficzne).

ALGORYTM:

Bez zmniejszenia ogólności możemy założyć, że obydwa drzewa mają tę samą:

- wysokość,
- liczbę liści na każdym poziomie.

```
1.  $\forall v$  - liść w  $T_i$   $\text{kod}(v) \leftarrow 0$ 
2. for  $j \leftarrow \text{depth}(T_1)$  downto  $1$  do
3.    $S_i \leftarrow$  zbiór wierzchołków  $T_i$  z poziomu  $j$  nie będących liśćmi
4.    $\forall v \in S_i$   $\text{key}(v) \leftarrow$  wektor  $\langle i_1, \dots, i_k \rangle$ , taki że
     -  $i_1 \leq i_2 \leq \dots \leq i_k$ 
     -  $v$  ma  $k$  synów  $u_1, \dots, u_k$  i  $i_l = \text{kod}(u_l)$ 
5.    $L_i \leftarrow$  lista wierzchołków z  $S_i$  posortowana leksykograficznie
     według wartości  $\text{key}$ 
6.    $L'_i \leftarrow$  otrzymany w ten sposób uporządkowany ciąg wektorów
7.   if  $L'_1 \neq L'_2$  then return ("nieizomorficzne")
8.    $\forall v \in L_i$   $\text{kod}(v) \leftarrow 1 + \text{rank}(\text{key}(v), \{\text{key}(u) \mid u \in L_i\})$ 
9.   Na początek  $L_i$  dołącz wszystkie liście z poziomu  $j$  drzewa  $T_i$ 
10. return ("izomorficzne")
```

Twierdzenie 2 Izomorfizm dwóch ukorzenionych drzew o n wierzchołkach może być sprawdzony w czasie $O(n)$.

Izomorfizm Drzew

- 1. Przejdź przez drzewo i przypisz każdemu węzłowi liczbę dzieci
- 2. Zaczynij od korzenia
- 3. Wywołaj się rekurencyjnie - jeśli zwracamy jest fałsz, to zwróć fałsz.
- 4. Węz dzieci tego węzła w drzewie T_1 i T_2 , a następnie posortuj je po ilości ich dzieci z kroku pierwszego.
- 5. Jeśli posortowane dzieci węzła z drzewa T_1 są równe tym z drzewa T_2 pod kątem liczby ich dzieci, to zwróć prawda wpp. fałsz.

Który z poniższych algorytmów sortowania może w najgorszym przypadku wykonać $\Omega(n^2)$ porównań:

- a) quicksort
- b) mergesort
- c) insertsort

Przypomnienie: $\Omega(n^2)$ oznacza nie mniej niż cn^2 dla pewnej stałej $c > 0$.

- a) quicksort - jeżeli znajdowanie pivota jest źle zrobione, tzn. odcina stałą liczbę elementów przy każdym partition, np. stosunek $1 : (n - 1)$, to wtedy złożoność to $n * O(n) = O(n^2)$
- b) mergesort - worst case $O(n \log n)$
- c) insertsort - posortowany lub odwrotnie posortowany ciąg będzie mieć $O(n^2)$

Treść

Jak uogólnić wykładowy algorytm szukania izomorfizmów drzew ukorzenionych na drzewa nieukorzenione.

Jaką ma złożoność nowy algorytm?

▼ Rozwiązanie

Ukorzeniamy drzewa w centroidzie.

Znalezienie centroidu robi się liniowo, np. BFS-em.

Dalej stosujemy algorytm wykładowy.

Treść

Przedstaw ideę szybkiego algorytmu sprawdzania izomorfizmu drzew. W jakim czasie działa ten algorytm?

Treść

Porównaj trudność problemu sprawdzania izomorfizmu drzew ukorzenionych i problemu sprawdzania izomorfizmu drzew nieukorzenionych.

- (**Z** 2pkt) Ułóż algorytm sortujący stabilnie i w miejscu ciągu rekordów o kluczach ze zbioru $\{1, 2, 3\}$.
- (1pkt) Podaj algorytm sprawdzający izomorfizm drzew nieukorzenionych.